

엄준서

서울 신반포로 23 길 | 010-2799-4465 | jseom818@gmail.com | <https://github.com/Eoo0m>

추천 시스템·표현학습·AI 기반 시스템 설계에 관심이 많은 ML 엔지니어입니다. 다양한 논문의 방법론을 직접 구현해 성능 개선으로 연결하고, 80K 트랙 규모의 음악 추천 시스템을 설계·배포·운영한 경험이 있습니다. 모델을 프로덕션 환경에서 실제 사용자 가치로 전환하는 데 집중합니다.

EXPERIENCE

SK ON | Intern, AI & Digital Transformation | 2026.02-2026.04

- 윤희유 수요 예측 모델 개발
 - LightGBM 기반 수요 예측 모델에서 고객 엔트로피를 활용해 수요 안정성을 반영한 피쳐로 WAPE 를 20% → 15%로 개선
- Databricks 기반 멀티모달 RAG 시스템 설계
 - 차트·도표 중심 리포트를 VLM 기반 캡셔닝 후 임베딩하여 검색하고, 원본 이미지를 VLM 에 입력해 답변 생성
 - VLM 기반으로 평가 질문 자동 생성 및 자동 채점을 수행해 RAG 성공률 정량 측정 (윤희유·LNG·사내 발표 자료 등 복잡한 도메인 리포트에서 성공률 83%)

Generative Lab | Software Engineer | 2025.06-2025.08

- 자연어 의도 기반 CJ Logistics API 를 동적으로 호출하는 tool-calling agent 로 CS 상담에서 배송조회·반품 등 자동화
- 월 10 만 건의 대규모 AI 상담 로그 분석 파이프라인 구축
 - AWS RDS(상담 내용) → AWS Lambda(CoT 분석) → Google Sheets 로 자동 분석 파이프라인 구축
 - 기존 대시보드를 상담 유형·이관사유 단위로 재구성하여 AI 모델 취약 영역을 정량적으로 진단할 수 있는 대시보드 구조로 개선

PROJECTS

Dynplayer | 음악 추천 시스템 설계·배포 (개인) | <https://dynplayer.win>

80K 트랙 음악 추천 시스템 설계·배포, 실제 사용자 환경에서 추천 및 검색 기능을 운영

- 추천 로직(Recommendation)
 - 그래프 임베딩에 랜덤 perturbation 을 추가한 대조학습으로 uniformity 를 개선해 롱테일 성능 향상 (Recall@10 0.1726 → 0.1901)
 - 사용자의 시퀀스를 기반으로 후보생성 투타워 모델 구현
 - HNSW 기반 ANN 검색 구조를 도입하여 retrieval 단계 최적화, Recall@10 98.9% 유지하며 latency 2 배 개선 (86.8ms → 42.0ms)

- **키워드 검색(Keyword Search)**

- Two-Tower(retrieval) 구조로 자연어 음악 검색 시스템 설계
- 플레이리스트 캡션을 짧은 태그 단위로 분할하여 학습, 짧은 키워드 쿼리 검색 성능 개선

AI Festival (미래에셋 X 네이버 클로바) | 우수상 (상금 500 만원)

- AI 필터버블을 해소하는 금융 AI 구현

DACON CTR prediction (Toss) | 43/726 (Top ~6%)

- LightGBM & Bi-LSTM + DCN 모델을 활용하여 시퀀스 데이터 복잡한 피처간 상호작용 학습

EDUCATION

Yonsei University | 2020.03-2026.08

- Bachelor of Industrial Engineering
- YBIGTA DS, Lead of Education

SKILLS

- **Languages:** Python, SQL
- **ML/DL:** PyTorch, HuggingFace, LangChain
- **Infra:** AWS, NCP, Linux, GitHub Actions, Supabase(pgvector), Cloudflare Pages
- **Backend/API:** FastAPI, Uvicorn